

Planificación de trayectoria profesional

Aixa Bazán Rodríguez

1. Descripción del problema

El ritmo acelerado de la transformación digital y la evolución de las tecnologías obligan a los profesionales a actualizar sus habilidades de manera continua.

Sin embargo, la planificación de una trayectoria formativa personalizada que conecte el perfil actual del estudiante con sus aspiraciones profesionales es una tarea compleja, especialmente cuando se deben considerar restricciones de prerrequisitos, carga temporal y la incertidumbre inherente al éxito en cada curso.

En este trabajo abordamos el diseño de un sistema inteligente que, a partir de la descripción en lenguaje natural del objetivo profesional de un usuario, genere automáticamente una secuencia óptima de cursos, evalúe su viabilidad mediante simulación y proporcione una valoración cualitativa comprensible para el usuario.

La optimalidad de la secuencia se define como la mínima duración total necesaria para completar la trayectoria, y se considera que una trayectoria es válida si respeta todos los prerrequisitos de los cursos que la componen y permite alcanzar el conjunto de habilidades objetivo especificado por el usuario.

2. Modelado formal

Para formalizar el problema se adopta una representación basada en STRIPS (*Stanford Research Institute Problem Solver*).

La formulación utilizada se describe mediante la tupla

$$\Pi = \langle P, O, I, G \rangle$$

donde:

- P es el conjunto de proposiciones que representan las habilidades del dominio.
- O es el conjunto de acciones (cursos) disponibles.
- $I \subseteq P$ representa el estado inicial del usuario, es decir, las habilidades que posee al comenzar el proceso de formación.
- $G \subseteq P$ representa el conjunto de habilidades objetivo necesarias para alcanzar la meta profesional deseada.

2.1. Representación de estados

Un estado se representa como el conjunto de proposiciones que son verdaderas en un momento dado. En nuestro dominio, dichas proposiciones corresponden a habilidades, por lo que un estado puede interpretarse como el conjunto de habilidades que posee el usuario en una etapa determinada de su trayectoria formativa.

Formalmente, cada estado se modela como un subconjunto de habilidades del dominio: $s \subseteq P$.

Bajo la hipótesis de mundo cerrado utilizada por STRIPS, toda habilidad que no pertenezca al estado se considera no adquirida.

El proceso de planificación comienza en el estado inicial (I) y tiene como objetivo alcanzar un estado (s) que satisfaga: $G \subseteq s$ es decir, un estado que contenga todas las habilidades requeridas para la profesión objetivo.

2.2. Representación de acciones

Cada curso se modela como una acción STRIPS:

$$a = \langle Pre(a), Add(a) \rangle$$

donde:

- $Pre(a)$ es el conjunto de habilidades prerequisite necesarias para cursar.
- $Add(a)$ es el conjunto de habilidades adquiridas al completar el curso.

A diferencia de la formulación STRIPS clásica, no se consideran efectos negativos (*delete effects*), ya que la adquisición de una habilidad no implica la pérdida de conocimientos previamente obtenidos.

Para adaptar el modelo al dominio de la planificación profesional, cada acción incorpora además información adicional relevante para la evaluación y optimización de trayectorias. Entre estos atributos se encuentran:

- **Nivel** (*level*): indica el nivel formativo del curso (Beginner, Intermediate, Advanced o Expert).
- **Duración** (*duration*): representa la duración nominal planificada del curso.
- **Dificultad** (*difficulty*): medida normalizada en el intervalo $[0, 1]$ que refleja la complejidad relativa del curso.
- **Descripción** (*description*): texto descriptivo que resume los contenidos y objetivos principales del curso.

Estos atributos no modifican la dinámica de transición entre estados, pero enriquecen la representación de las acciones y permiten optimizar y evaluar las trayectorias generadas de acuerdo con las características propias del dominio.

2.3. Función de transición

Las transiciones entre estados se modelan mediante una función de transición que, a partir de un estado y una acción aplicable, devuelve el estado sucesor. Dado que los estados se representan como conjuntos de hechos (en nuestro caso, identificadores de habilidades), la función de transición asociada a la instancia STRIPS $\langle P, O, I, G \rangle$ es

$$\gamma : 2^P \times A \rightarrow 2^P,$$

donde P es el conjunto de todas las habilidades, A es el conjunto de cursos, y $\gamma(s, a)$ representa el estado resultante de aplicar el curso a al estado s .

Formalmente, una acción a puede aplicarse sobre un estado s si sus prerequisites están incluidos en s :

$$Pre(a) \subseteq s.$$

Cuando la acción es aplicable, el estado sucesor se obtiene añadiendo los efectos positivos de la acción al estado actual:

$$\gamma(s, a) = s \cup Add(a).$$

2.4. Función de costo

Dado que el objetivo principal del sistema es minimizar el tiempo total necesario para alcanzar una meta profesional, cada acción posee un costo asociado igual a su duración:

$$cost(a) = duration(a)$$

El costo de una trayectoria formada por la secuencia de cursos

$$\pi = \langle a_1, a_2, \dots, a_n \rangle$$

se define como:

$$Cost(\pi) = \sum_{i=1}^n cost(a_i).$$

Por tanto, el problema consiste en encontrar, entre todas las secuencias de cursos que respetan los prerequisites y permiten alcanzar las habilidades deseadas, aquella que requiere el menor tiempo total de formación.

3. Descripción del dataset

La disponibilidad de datos constituye una de las principales limitaciones para este tipo de problemas. No existen conjuntos de datos públicos que modelen simultáneamente **habilidades**, **cursos**, **prerequisites** y **trayectorias formativas completas** dentro de un mismo dominio. Por este motivo, se optó por generar un **dataset sintético** específicamente diseñado para las necesidades del sistema.

El proceso de generación se estructura en dos etapas principales: construcción de la base de conocimiento y generación automática de cursos.

3.1. Construcción de la base de conocimiento

En una primera fase se construye una representación estructurada del dominio profesional utilizando un **Modelo de Lenguaje de Gran Escala (LLM)**. A partir del nombre de un dominio (por ejemplo, Ciencia de Datos, Ciberseguridad o Cocina), el modelo genera un conjunto de habilidades organizadas según distintos niveles de complejidad.

Para cada habilidad se especifican los siguientes elementos:

- Nombre de la habilidad.
- Nivel de dificultad.
- Habilidades prerequisite necesarias para adquirirla.
- Descripción

Además, las habilidades se agrupan en **grupos temáticos** (*skill groups*), permitiendo identificar áreas de conocimiento relacionadas que posteriormente servirán como base para la generación de cursos coherentes.

3.2. Generación automática de cursos

Una vez construida la base de conocimiento, se genera un catálogo de cursos que permitirá alcanzar las habilidades definidas.

Para cada curso, el sistema selecciona inicialmente un conjunto de habilidades relacionadas que serán impartidas de forma conjunta. A partir de las dependencias existentes entre dichas habilidades, se determinan automáticamente los **prerrequisitos del curso**.

Posteriormente se asignan los atributos restantes del curso:

- **Nivel formativo:** determinado por el nivel máximo de las habilidades impartidas.
- **Duración:** estimada según la cantidad y complejidad de las habilidades.
- **Dificultad:** valor normalizado en el intervalo $[0, 1]$ calculado a partir de las habilidades enseñadas.
- **Descripción:** resumen textual generado automáticamente.

El resultado es un catálogo de cursos consistente con la estructura de dependencias del dominio y adecuado para ser utilizado por el planificador.

3.3. Dataset resultante

El dataset final se almacena en dos archivos JSON principales. El archivo `skills.json` contiene el conjunto de habilidades. Por su parte, `courses.json` almacena el catálogo de cursos generados.

Esta representación proporciona toda la información necesaria para formular el problema de planificación, incluyendo estados, acciones, prerequisites y costes asociados.

En el presente trabajo se emplea el dominio de **Ciencia de Datos**, generado mediante el procedimiento descrito anteriormente. El conjunto resultante contiene **30 habilidades y 50 cursos**.

Finalmente, se aplicó una etapa de **postprocesamiento** sobre los cursos generados con el objetivo de mejorar la calidad de los nombres y descripciones producidos, garantizando una mayor coherencia entre el contenido del curso y las habilidades que este imparte.

4. Diseño del algoritmo

Una vez modelado el problema mediante STRIPS, la generación de trayectorias profesionales puede formularse como un problema de búsqueda. Siguiendo los enfoques clásicos de planificación, se optó por realizar búsqueda en el espacio de estados, partiendo del estado inicial del usuario y aplicando sucesivamente acciones válidas hasta alcanzar un estado que satisfaga las habilidades objetivo.

4.1. Planificadores implementados

Con el objetivo de analizar el impacto de diferentes estrategias, se implementaron tres planificadores.

4.1.1. Búsqueda de costo uniforme (UCS)

La primera variante utiliza búsqueda de costo uniforme. Este algoritmo garantiza encontrar una trayectoria óptima respecto a la función de costo definida, aunque suele explorar una gran cantidad de estados debido a la ausencia de información heurística.

4.1.2. A* con heurística basada en habilidades pendientes

La segunda variante emplea una heurística simple. Consiste en contabilizar cuántas habilidades objetivo aún no han sido adquiridas. Sea

$$M(s) = G \setminus s$$

el conjunto de habilidades objetivo faltantes en el estado s . La heurística se define como:

$$h_{basic}(s) = |M(s)|$$

La intuición detrás de esta estimación es que, cuanto mayor sea el número de habilidades pendientes, más lejos se encuentra el estado actual de satisfacer el objetivo.

Aunque esta heurística ignora la duración de los cursos y las dependencias existentes entre habilidades, proporciona una medida sencilla del progreso realizado y resulta computacionalmente muy barata de calcular. Sin embargo, diferentes habilidades pueden requerir esfuerzos muy distintos para ser alcanzadas, por lo que su capacidad de discriminación es limitada.

4.1.3. A* con heurística Max-Min (planificador principal)

La tercera variante utiliza una heurística basada en los costos mínimos necesarios para adquirir las habilidades objetivo pendientes, ignorando los prerrequisitos. Esta es la heurística principal del sistema.

Para cada habilidad $p \in P$, se precomputa el costo mínimo de cualquier curso capaz de enseñarla:

$$m(p) = \min\{\text{cost}(a) \mid a \in A, p \in \text{Add}(a)\}$$

La heurística se define entonces como:

$$h_{\text{maxmin}}(s) = \max_{p \in G \setminus s} m(p)$$

Esta heurística es admisible porque, para alcanzar una habilidad p que aún no se posee, es necesario cursar al menos algún curso que la enseñe, y el coste mínimo posible para adquirir p es $m(p)$. Al tomar el máximo sobre todas las habilidades pendientes, se obtiene una cota inferior del coste total restante (no se pueden adquirir todas simultáneamente más rápido que el tiempo necesario para la más costosa). La relajación de los prerrequisitos solo puede reducir el coste estimado, por lo que la estimación nunca supera el coste real.

5. Rol del LLM en el sistema

El LLM participa en dos etapas fundamentales del sistema: la interpretación de objetivos profesionales y la evaluación cualitativa de las trayectorias generadas.

El sistema emplea el modelo *Mistral Small* (`mistral-small-latest`) mediante la API de Mistral AI. Las consultas se realizan utilizando el formato conversacional de mensajes (*chat completions*). Dado que las tareas desarrolladas requieren respuestas consistentes y estructuradas, se utilizaron parámetros de generación conservadores, incluyendo una temperatura de 0.1, *top-p*=0.95, *frequency penalty*=0.5 y *presence penalty*=0.3.

5.1. Interpretación de objetivos profesionales

Los usuarios expresan sus metas profesionales mediante descripciones en lenguaje natural, las cuales no pueden ser utilizadas directamente por el planificador. Por ejemplo, un usuario puede indicar:

“Soy graduado en matemáticas y me gustaría convertirme en científico de datos especializado en aprendizaje automático.”

A partir de esta descripción, el LLM identifica dos conjuntos de habilidades:

- **Habilidades actuales** (*current_skills*): habilidades que el usuario ya posee o que pueden inferirse razonablemente a partir de su perfil.
- **Habilidades objetivo** (*goal_skills*): habilidades que el usuario debe adquirir para alcanzar su meta profesional.

Para garantizar la consistencia de la representación, el modelo recibe el catálogo completo de habilidades disponibles y se le solicita seleccionar únicamente elementos pertenecientes a dicho conjunto. Además, la salida generada es sometida a una etapa de validación, en la que se verifica el formato de la respuesta y se descartan habilidades que no existan en el dominio considerado.

Este proceso permite convertir descripciones expresadas en lenguaje natural en conjuntos de habilidades válidos que pueden emplearse directamente como estados iniciales y objetivos dentro del planificador.

5.2. Evaluación de trayectorias

Una vez generada la secuencia de cursos, el sistema incorpora una etapa de evaluación cualitativa a cargo del mismo LLM.

En esta fase, el modelo actúa como un asesor experto en formación y examina la trayectoria propuesta atendiendo a los siguientes criterios, cada uno valorado en una escala de 1 a 5 (1 = muy deficiente, 5 = excelente):

- **Cumplimiento del objetivo del usuario:** ¿la trayectoria satisface lo que el usuario pidió, considerando sus habilidades iniciales y sus metas declaradas?
- **Progreso profesional:** ¿el plan permite un crecimiento significativo en el conocimiento del estudiante, añadiendo nuevas habilidades de forma eficiente?
- **Puntuación global:** un juicio sintético que resume la calidad general de la trayectoria.

El resultado es un texto estructurado con puntuaciones por criterio, lo que facilita la comprensión inmediata de la calidad del plan por parte del usuario final. Este análisis cualitativo complementa los resultados de la simulación Monte Carlo: mientras que la simulación cuantifica la robustez, la evaluación del LLM ofrece un juicio sobre la eficiencia formativa, aportando así una visión más completa de la solución generada.

6. Simulación de trayectorias

La planificación obtenida mediante los algoritmos de búsqueda proporciona una trayectoria óptima respecto a la duración total de los cursos. Sin embargo, esta solución representa una estimación idealizada, ya que asume que el estudiante completa cada curso con éxito en el tiempo previsto.

Con el objetivo de evaluar la viabilidad práctica de las trayectorias generadas, se incorpora una etapa de simulación basada en el **método de Monte Carlo**. Esta etapa permite estimar el comportamiento de una población de estudiantes con diferentes capacidades de aprendizaje y analizar el impacto de factores como la dificultad de los cursos, los intentos de aprobación y el abandono de la formación.

6.1. Modelo del estudiante

Cada estudiante simulado se caracteriza mediante una habilidad latente θ , generada a partir de una distribución normal:

$$\theta \sim \mathcal{N}(\mu, \sigma)$$

donde θ representa la capacidad general del estudiante para superar los cursos de la trayectoria.

Por su parte, cada curso posee un parámetro de dificultad derivado de su atributo *difficulty_score*.

La probabilidad de aprobar cada curso se modela mediante una función logística inspirada en el modelo de Rasch, donde intervienen una habilidad latente del estudiante (θ) y un parámetro de dificultad asociado al curso (b). La expresión general es:

$$P(\text{aprobar el curso}_i \mid \theta, b_i) = \frac{1}{1 + e^{-(\theta - b_i)}}$$

Sin embargo, a diferencia del modelo Rasch clásico, la habilidad del estudiante no permanece constante durante la simulación, sino que evoluciona en función de los éxitos y fracasos acumulados. Por tanto, el modelo utilizado debe interpretarse como una adaptación simplificada para representar procesos de aprendizaje progresivo y no como una aplicación estricta de la Teoría de Respuesta al Ítem.

De esta forma, estudiantes con una habilidad superior a la dificultad del curso presentan una mayor probabilidad de éxito.

6.2. Simulación del proceso formativo

Para cada trayectoria generada se ejecutan múltiples simulaciones independientes. Durante cada simulación:

1. Se genera un estudiante con una habilidad inicial aleatoria.

2. El estudiante intenta completar los cursos siguiendo el orden propuesto por el planificador.
3. Cada intento posee una probabilidad de aprobación calculada mediante el modelo logístico.
4. Si el estudiante aprueba, su habilidad aumenta ligeramente para reflejar el aprendizaje adquirido.
5. Si suspende, puede volver a intentarlo hasta alcanzar un número máximo de intentos.
6. Tras cada fracaso existe una probabilidad de abandono que aumenta con la dificultad del curso y el número de intentos realizados.

Además, la duración real de cada curso se modela mediante una perturbación aleatoria alrededor de la duración planificada, permitiendo representar diferencias individuales en el ritmo de aprendizaje.

6.3. Métricas obtenidas

A partir de las simulaciones se calculan diversas métricas para caracterizar la calidad de una trayectoria:

- **Tasa de éxito:** proporción de estudiantes que completan todos los cursos del plan.
- **Intervalo de confianza del 95 %:** estimación de la incertidumbre asociada a la tasa de éxito, calculada mediante el intervalo de Wilson.
- **Tiempo medio y mediano:** duración real observada entre los estudiantes que completan la trayectoria.
- **Probabilidad de alcanzar cada curso:** proporción de estudiantes que llegan a iniciar un curso determinado.
- **Probabilidad de aprobar cada curso:** probabilidad de superar un curso condicionada a haber llegado a él.
- **Número medio de intentos:** cantidad promedio de intentos necesarios para aprobar cada curso.

Gracias al análisis de las mismas es posible identificar cursos especialmente difíciles, cuellos de botella en la progresión formativa y trayectorias que, aun siendo óptimas desde el punto de vista temporal, presentan una baja probabilidad de completarse con éxito.

7. Metodología experimental

Todos los experimentos se realizaron utilizando el dataset sintético generado para el dominio de Ciencia de Datos descrito anteriormente.

Cada experimento se definió mediante un archivo de configuración en formato JSON, el cual especifica:

- La descripción del objetivo profesional proporcionada por el usuario.
- El dataset utilizado.
- El algoritmo de planificación empleado.
- La activación o no del registro de estadísticas de planificación.
- La ejecución o no de la simulación Monte Carlo.
- La ejecución o no de la evaluación cualitativa mediante LLM.

Esta estructura permite reproducir fácilmente los experimentos y comparar distintas configuraciones del sistema bajo las mismas condiciones.

7.1. Comparación de algoritmos de planificación

El primer experimento tuvo como objetivo comparar el rendimiento de los tres algoritmos de búsqueda implementados.

Para ello se utilizó la siguiente descripción de objetivo profesional:

“Me gustaría aprender a consultar bases de datos con SQL y a hacer visualizaciones básicas y limpieza de datos.”

A partir de esta descripción, el módulo de interpretación basado en LLM identificó las habilidades objetivo:

$$G = \{\text{sql_basico}, \text{visualizacion_de_datos}, \text{limpieza_de_datos}\}.$$

No se proporcionaron habilidades iniciales, por lo que el proceso de planificación comenzó desde el estado vacío.

En todos los casos se obtuvo la misma trayectoria de formación compuesta por seis cursos, con un costo total de 484 horas de formación, evidenciando que los tres métodos encuentran el plan óptimo.

Para comparar el rendimiento de los algoritmos se registraron tres métricas:

- **Nodos expandidos:** estados extraídos de la frontera y procesados.
- **Nodos generados:** sucesores creados durante la búsqueda.
- **Frontera máxima:** mayor número de estados en memoria simultáneamente.

Los resultados se presentan en la Figura 1.




Figura 1: Métricas de búsqueda por planificador.

La búsqueda de costo uniforme y A* con heurística básica presentan comportamientos muy similares, explorando aproximadamente 380 estados y generando más de 9000 nodos durante la búsqueda.

Por el contrario, la heurística Max-Min reduce considerablemente el espacio explorado. El número de nodos expandidos disminuye de 385 a 202, lo que representa una reducción cercana al 48 %. Asimismo, el número de estados generados se reduce de 9215 a 4339, equivalente a una disminución aproximada del 53 %.

En cuanto al consumo de memoria, la frontera máxima de UCS y A* básico coincide en 312 estados, lo que refleja una evolución casi idéntica de sus estructuras de búsqueda. La heurística Max-Min, en cambio, reduce la frontera a 233 estados.

Estos resultados indican que la heurística Max-Min proporciona una estimación más informativa del costo restante, permitiendo dirigir la búsqueda hacia regiones más prometedoras del espacio de estados y evitando expansiones innecesarias. De esta forma se evidencia que la calidad de la heurística es un factor determinante en el rendimiento práctico del algoritmo A*.

7.2. Evaluación completa del sistema

Además del experimento de comparación de planificadores, se realizaron tres experimentos adicionales con el objetivo de evaluar el comportamiento completo del sistema bajo distintos perfiles profesionales.

Dichos experimentos utilizan el planificador A* con heurística Max-Min, ejecutan la simulación Monte Carlo y activan la evaluación cualitativa mediante LLM. La Tabla 1 recoge los indicadores principales.

Cuadro 1: Resultados de simulación y evaluación cualitativa de las trayectorias generadas para los tres perfiles profesionales.

Métrica	Analista	Científico Jr.	Ingeniero ML
Número de cursos	6	6	10
Duración (h)	480	468	1091
Éxito simulación	79.75 %	80.18 %	44.08 %
Tiempo medio (h)	588.2	575.8	1394.6
Cumplimiento (LLM)	4/5	5/5	5/5
Progreso profesional (LLM)	5/5	4/5	5/5
Puntuación global (LLM)	4.5/5	4.5/5	5/5

7.2.1. Experimento: Analista de datos

Descripción proporcionada: *“Quiero trabajar como analista de datos. Ya sé usar Excel y tengo nociones de estadística descriptiva. Necesito aprender SQL para consultar bases de datos, mejorar mis habilidades de visualización con herramientas como Tableau o Power BI, y comprender los fundamentos de la limpieza de datos.”*

El intérprete LLM detectó las siguientes habilidades:

- **Iniciales:** estadistica_descriptiva, programacion_basica.
- **Metas:** sql_basico, visualizacion_de_datos, limpieza_de_datos.

El planificador generó una trayectoria de 6 cursos (480 h planificadas). La simulación Monte Carlo obtuvo una tasa de éxito del 79.75 % y un tiempo medio real de 588.2 h, superior al nominal. El plan cubre las metas pero incluye contenidos no solicitados (cálculo, machine learning, big data) forzados por las dependencias del catálogo.

La evaluación cualitativa del LLM otorgó 4/5 en cumplimiento del objetivo, 5/5 en progreso profesional y una puntuación global de 4.5/5, señalando que la trayectoria satisface lo solicitado aunque incorpora formación adicional no requerida por el usuario.

7.2.2. Experimento: Científico de datos junior

Descripción proporcionada: *“Soy graduado en matemáticas y tengo conocimientos básicos de programación en Python. Quiero ser científico de datos junior. Me falta aprender sobre visualización de datos, machine learning básico (regresión, clasificación) y algo de estadística inferencial. También me interesaría tener nociones de big data.”*

El intérprete LLM detectó las siguientes habilidades:

- **Iniciales:** matematicas_basicas, programacion_basica, python_para_ciencia_de_datos.
- **Metas:** visualizacion_de_datos, machine_learning_basico, modelos_de_regresion, estadistica_inferencial, big_data_basico.

El planificador generó una trayectoria de 6 cursos (468 h planificadas). La simulación Monte Carlo obtuvo una tasa de éxito del 80.18 % y un tiempo medio real de 575.8 h, superior al nominal. El plan cubre todas las metas solicitadas, aunque incluye contenidos complementarios (SQL, cálculo) requeridos por las dependencias del catálogo.

La evaluación cualitativa del LLM otorgó 5/5 en cumplimiento del objetivo, 4/5 en progreso profesional y una puntuación global de 4.5/5, señalando que la secuencia es lógica aunque ciertos temas se introducen antes de lo esperado, con una dificultad acumulada exigente pero manejable.

7.2.3. Experimento: Ingeniero de Machine Learning

Descripción proporcionada: *“Mi objetivo es convertirme en ingeniero de machine learning. Tengo buena base de programación en Python y conozco librerías como pandas y scikit-learn. Quiero profundizar en deep learning, despliegue de modelos en la nube (AWS/GCP) y en herramientas de MLOps como Docker y Kubernetes.”*

El intérprete LLM detectó las siguientes habilidades:

- **Iniciales:** `python_para_ciencia_de_datos`, `machine_learning_basico`.
- **Metas:** `deep_learning`, `cloud_computing_para_ciencia_de_datos`, `ciencia_de_datos_en_produccion`.

El planificador generó una trayectoria de 10 cursos (1091 h planificadas). La simulación Monte Carlo obtuvo una tasa de éxito del 44.08 % y un tiempo medio real de 1394.6 h, muy superior al nominal. El último curso de la secuencia concentra la mayor dificultad (0.75) y requiere en promedio 1.91 intentos, lo que explica en buena medida la baja tasa de éxito y el elevado tiempo observado.

La evaluación cualitativa del LLM otorgó 5/5 en cumplimiento del objetivo, 5/5 en progreso profesional y una puntuación global de 5/5. Sin embargo, esta valoración no refleja la fragilidad revelada por la simulación, lo que evidencia la importancia de complementar el análisis cualitativo con métricas cuantitativas de robustez.

8. Limitaciones y posibles mejoras

A continuación se discuten las principales limitaciones identificadas en el sistema actual y se proponen vías de mejora para trabajos futuros.

- **Catálogo de cursos limitado.** El catálogo actual obliga a incluir cursos con contenidos no solicitados para alcanzar ciertas habilidades. *Mejora:* ampliar el catálogo con cursos más directos.
- **Evaluación cualitativa sin datos de simulación.** La evaluación del LLM no considera los resultados de la simulación Monte Carlo, por lo que puede otorgar puntuaciones altas a planes frágiles. *Mejora:* incorporar

métricas de simulación en el prompt de evaluación para que la puntuación de “Robustez” refleje el riesgo real.

- **Simulación simplificada.** El modelo de simulación emplea parámetros fijos (dificultad, repetición, abandono) que no capturan la variabilidad real del rendimiento estudiantil. *Mejora:* calibrar el simulador con datos históricos reales de cursos y estudiantes, lo que permitiría reflejar la heterogeneidad de perfiles y obtener predicciones más fiables.
- **Coste basado solo en la duración.** La optimalidad se define exclusivamente como la mínima duración total, ignorando otros factores como la dificultad acumulada. *Mejora:* extender la función de coste para incluir una combinación ponderada de tiempo, dificultad y otros criterios configurables por el usuario.